Граф трансформерийн сүлжээний өргөний нөлөөллийг шинжлэх нь

Явц 2

Баяр-Эрдэнэ Барсболд

2026 оны 10-р сар

Ажлын зорилго

Сүлжээний өргөнийг багасгах зарим боломжуудыг шинжлэх.

- **Бодлого:** оройн хос бүр холбогдсон эсэхийг тогтоох
- **Өргөн** m = embedding-ийн хэмжээс (толгойн хэмжээс 8, feed-forward давхарга $4m$); гүнийг 6-д тогтмол барьсан
- **Критик өргөн** m^***:** тестийн хосын нарийвчлал 0.95-д хүрэх хамгийн бага m
- **Онолын үр дүнгээр** энэ бодлогыг **илэрхийлэхэд** бага өргөн хангалттай. $O(\log N)$ гүнтэй үед $\approx \sqrt{N}$ (Sanford тэргүүтэй судлаачид, 2024), тогтмол гүнтэй үед нэг ба хоёр циклийг ялгахад $O(n)$, дурын графын холбоост эсэхэд $O(n \log^3 n)$. Бид **сургалтаар** шийдэд хүрэхэд шаардлагатай өргөнийг хэмжсэн.

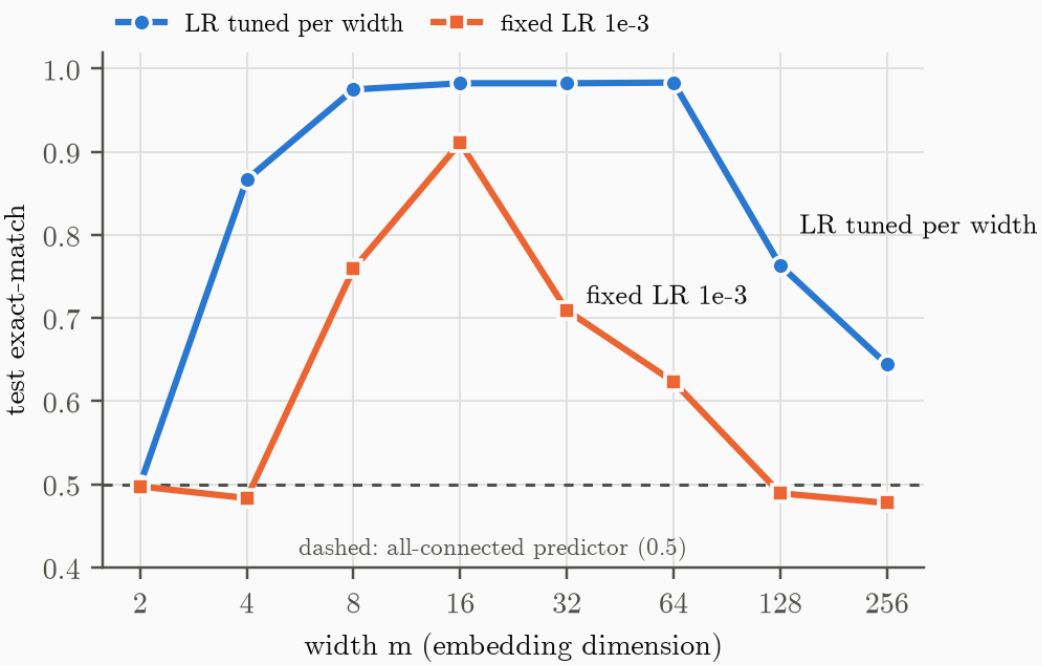
Хоёр алхамтай. (1) Шаардлагатай өргөн графын хэмжээ n-ийн хамт хэрхэн өсөхийг хэмжих. (2) Түүнийг юу бууруулахыг шалгах.

Үр дүнгийн тойм

үр дүн	агуулга
$m^* \propto n^{1.74}$	нэг сургалтын хурдаар, дөрвөн хэмжээнд хийсэн эцсийн хэмжилт (90 %: 1.59–1.90)
2, 4 алхмын мөр	өргөн 2.3–3.2 дахин буурсан, өсөлт $n^{1.27}$ / $n^{1.03}$
ирмэгийн токен	4 дахин олон алхамтай ч хөршийн мөрөөс ≥ 2.2 дахин илүү өргөн шаардсан
RWSE	нөлөөгүй, түгээмэл 16 алхмын хувилбар нь хариуг задруулсан
probe	холбоост эсэх нь давхарга бүрт аажмаар бүрэлдэж, хос оройгоос уншигдсан
өгөгдлийн шалгалт	Sanford болон Yehudai тэргүүтэй судлаачдын өгөгдлийг локал дүрмээр шийдэж болсон

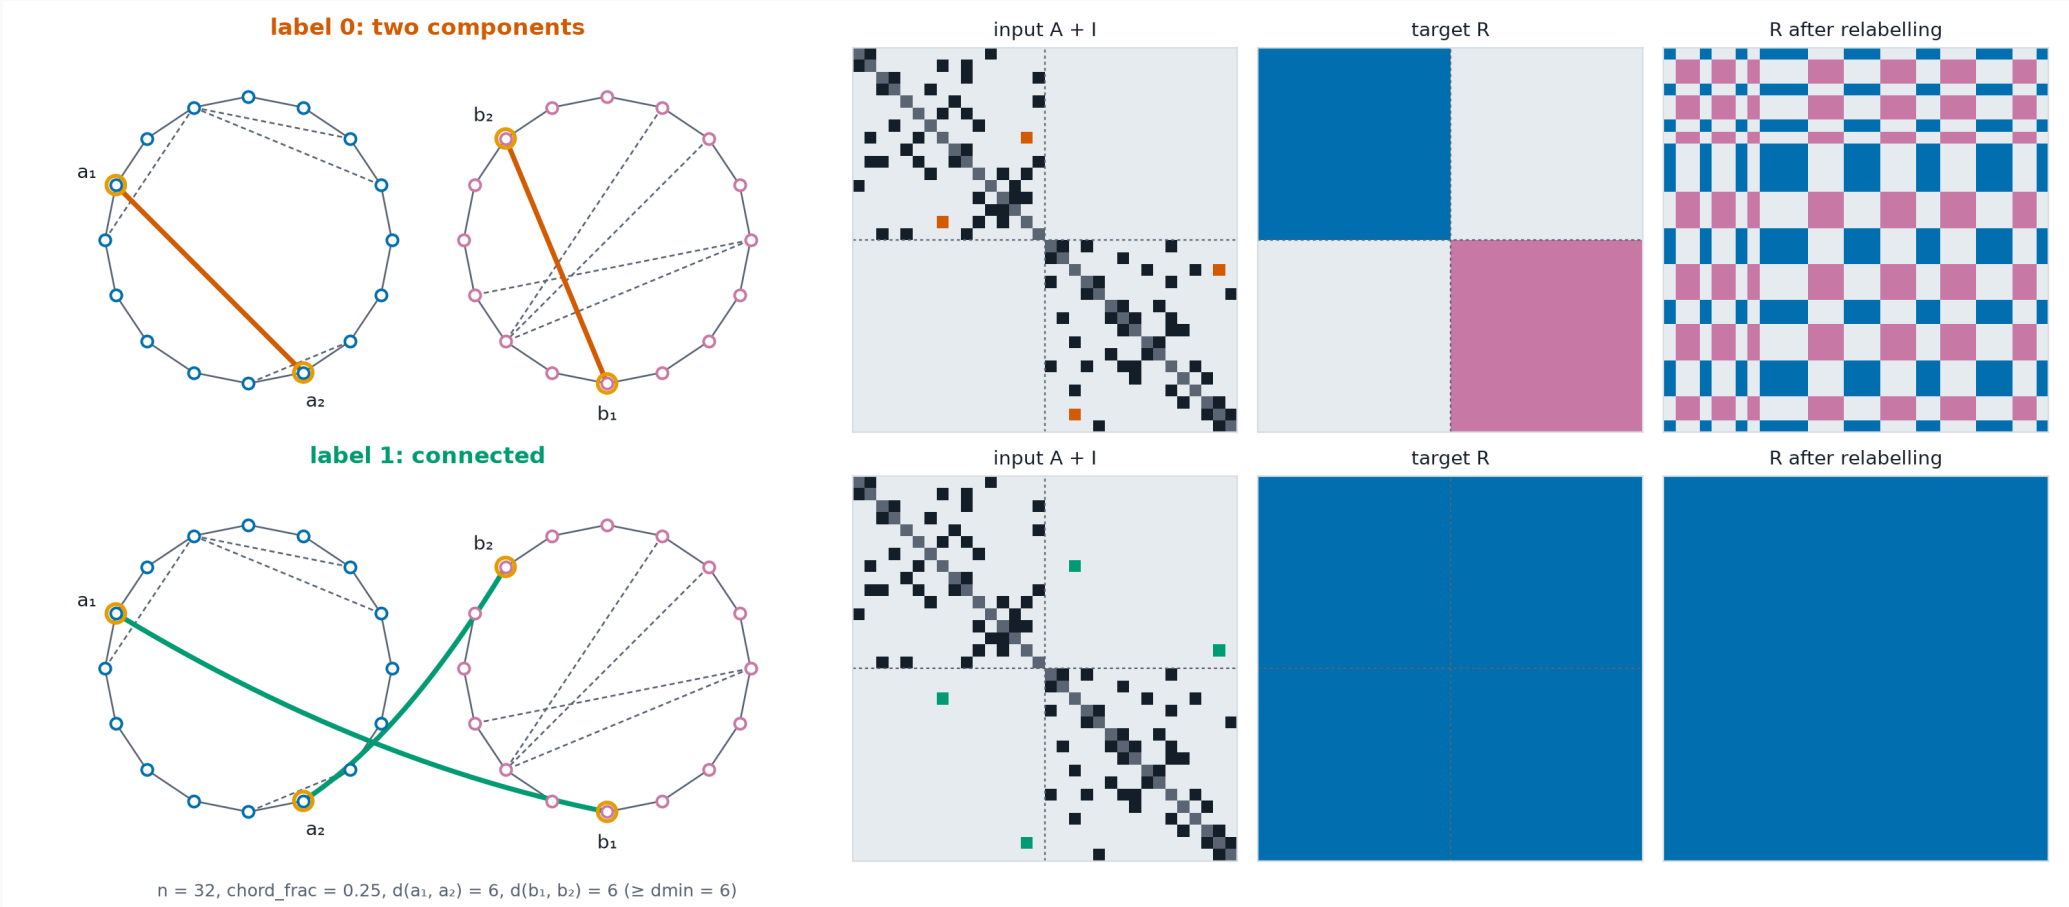
1-р хэсэг — Шаардлагатай өргөн хэрхэн өсөх вэ

Өргөнийг хэмжихэд нямбай аргачлал хэрэгтэй



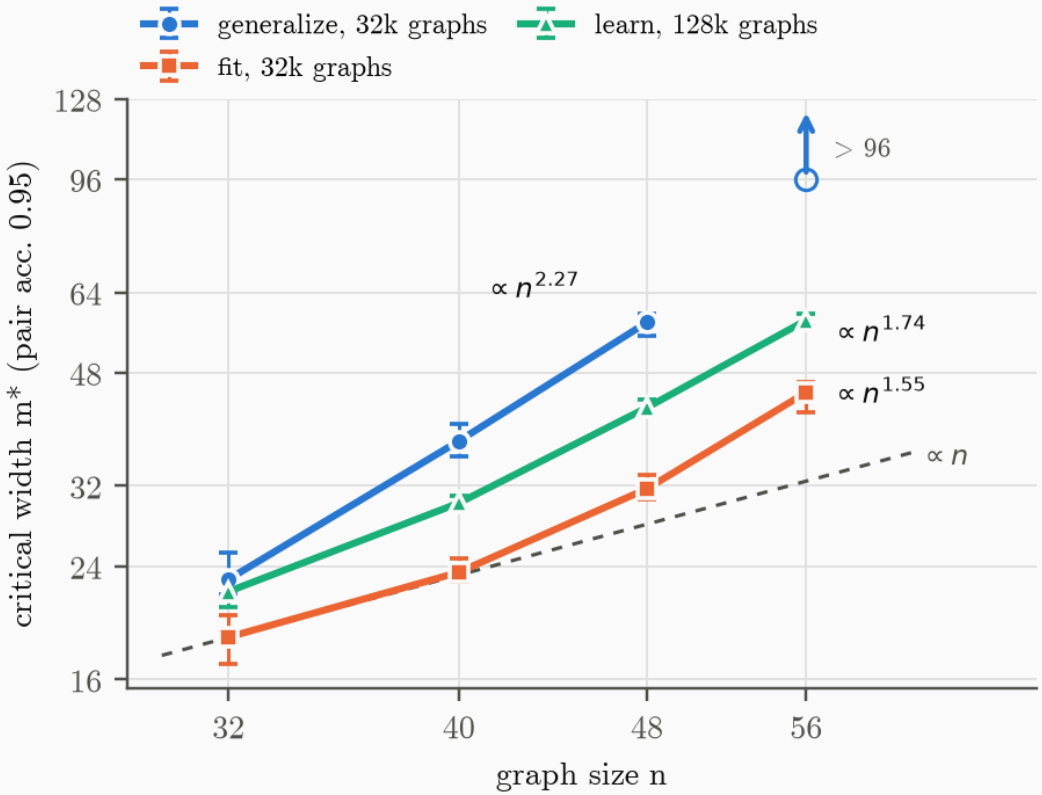
- **Сургалтын хурд:** нэг тогтмол хурдтай үед өргөн загварууд тохируулсан хурдтай үеийнхээс муу үр дүн үзүүлсэн, оновчтой хурд өргөн нэмэгдэхэд буурсан ⟶ өргөн бүрт тохируулсан
- **Өгөгдөл:** граф цөөн үед өргөн загварууд цээжилсэн ⟶ 128 000 граф
- **Өгөгдлийн шалгалт:** анхны өгөгдөл оройн индекс, графын статистикаар хариуг задруулж байсан ⟶ бүх локал дүрэм санамсаргүй таамаглалын түвшинд байх `swap` өгөгдөл

swap өгөгдөл: ангиудыг локал шинжээр ялгах боломжгүй



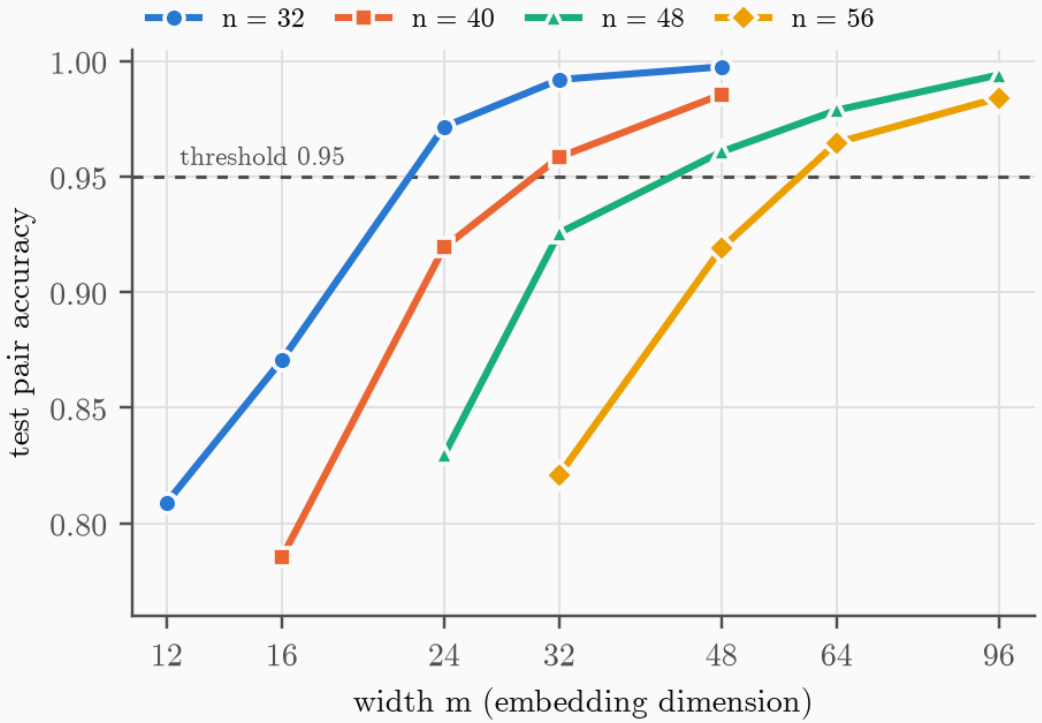
Хоёр тусдаа холбоост граф үүсгээд, тус бүрээс хоорондоо хол зайтай хоёр орой сонгоно. Холбоогүй ангид граф бүрийн хос оройг хооронд нь, холбоост ангид хоёр графыг хооронд нь холбоно. Хоёр ангид ирмэгийн тоо, оройн зэрэг ижил. Оройн дугаарыг санамсаргүйгээр сэлгэнэ.

Өгөгдөл хангалттай үед таарах ба ерөнхийлөх өргөн давхцсан



- 32 000 граф: таарах өргөн $\propto n^{1.55}$, ерөнхийлөх өргөн $\propto n^{2.27}$, зөрүү нь n-ийн хамт өссөн
- 128 000 граф, ижил 24 000 алхам: хоёр өргөн $\approx$ 2-ын зөрүүтэй давхцсан
- Босгоос нарийн загвар огт сураагүй. $n = 128$ үед 128 хүртэлх өргөнтэй ямар ч загвар суурь таамаглалаас давж гараагүй

Гол үр дүн: $m^* \propto n^{1.74}$



n	таарах	ерөнхийлөх	m^*/n
32	20.9	21.9	0.68
40	28.2	30.1	0.75
48	38.5	42.4	0.88
56	52.7	57.9	1.03
өсөлт	$n^{1.65}$	$n^{1.74}$	

128 000 граф, 24 000 алхам, сургалтын хурд 10^{-3}, гүн 6, 2 seed; bootstrap-ийн 90 % завсар 1.59–1.90

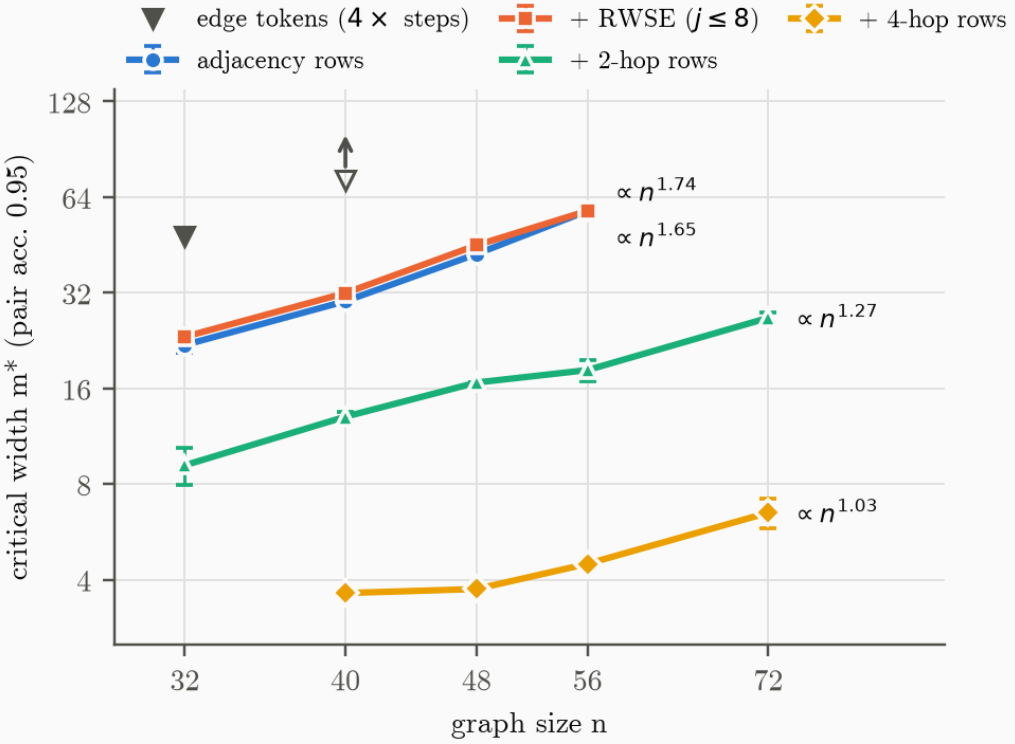
Өсөлт бүх шалгалтыг давсан

шалтгаан нь...	**шалгалт**	**үр дүн**
өгөгдөл хомс уу?	32k $\longrightarrow$ 64k $\longrightarrow$ 128k граф	зөрүү арилсан, **өсөлт шугаманаас хурдан хэвээр**
сургалт богино уу?	алхмын тоог 2 дахин	**критик өргөн өөрчлөгдөөгүй**
сургалтын хурд уу?	$3 \cdot 10^{-3}$ ба 10^{-3}	**өсөлтийн зэрэг 1.94 $\longrightarrow$ 1.74**
n хэмжээст оролт уу?	96 хэмжээст санамсаргүй проекц	**$n = 40$-өөс 56 хүртэл 2 дахин өссөн**
санамсаргүй хэлбэлзэл үү?	seed бүрийн огтлолцол	**seed-үүд $\approx \pm$ 3-ын зөрүүтэй**

Холбоост эсэхийг **сурахад** шаардлагатай өргөн n-ээс хурдан өссөн. Харин түүнийг **илэрхийлэхэд** $\approx \sqrt{N}$ өргөн хангалттай.

2-р хэсэг — Шаардлагатай өргөнийг юу бууруулах вэ

Алхмуудыг урьдчилан өгөхөд өргөн ба түүний өсөлт буурсан



оролт	$n = 32$	$n = 56$	өсөлт
хөршийн мөр	21.9	57.9	$n^{1.74}$
+ RWSE ($j \le 8$)	23.3	57.9	$n^{1.65}$
+ 2 алхмын мөр	9.2	18.3	$n^{1.27}$
+ 4 алхмын мөр	3.5	4.5	$n^{1.03}$

- Токен бүрт k алхмын хүрэх чанарын мөрийг нэмсэн. Энэ мөр дангаараа графуудын **0 %**-ийг зөв шийдсэн тул хариуг задруулаагүй
- **2 алхам өгөхөд өргөн 2.3–3.2 дахин буурсан,** 4 алхам өгөхөд өсөлт бараг шугаман болсон

Өргөнийг бууруулаагүй кодчиллууд

Ирмэгийн токен (Sanford тэргүүтэй судлаачдын кодчилол, бүх хосын шошготой)

	$n = 32$	$n = 40$
хөршийн мөр	21.9	30.1
ирмэгийн токен, 24k алхам	≤ 96-д үгүй	≤ 96-д үгүй
ирмэгийн токен, 96k алхам	48.2	≥ 72

Загвар эхлээд оройн хөршүүдийг цуглуулж сурах шаардлагатай тул 4 дахин олон алхамтай ч **≥ 2.2 дахин илүү өргөн** шаардсан.

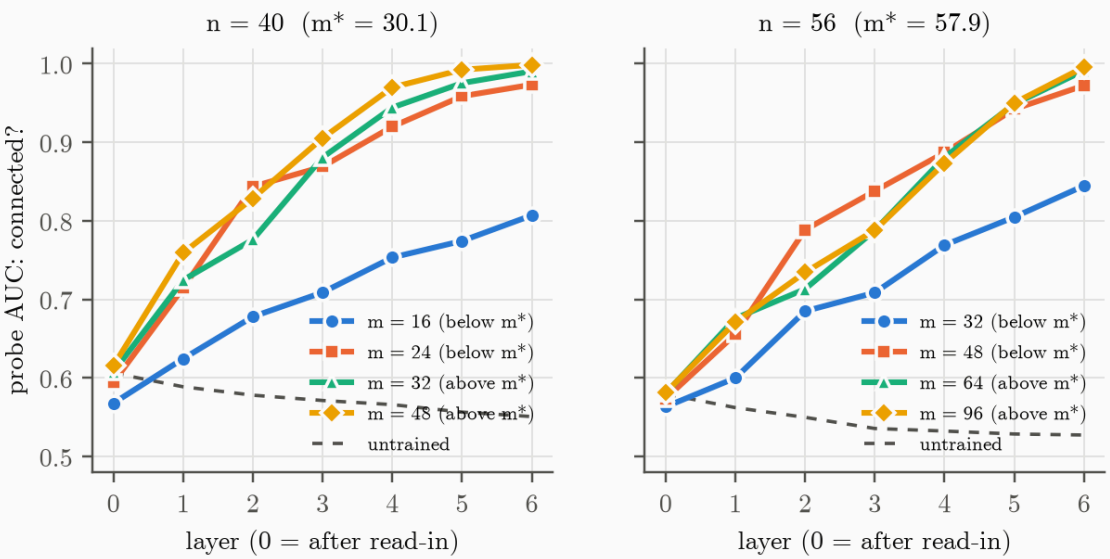
RWSE (санамсаргүй алхмын буцах магадлал, GraphGPS-ийн стандарт кодчилол)

- $j \leq 8$ алхам: аль ч хэмжээнд **өөрчлөлтгүй**
- $j \leq 16$ (түгээмэл утга) өргөнийг 17–22 %-иар бууруулсан нь хариуг **задруулсантай** холбоотой. Энэ кодчилол дангаараа холбоост эсэхийг 0.90 нарийвчлалтай ($n = 40$) таамагласан

Урьдчилан тооцоолсон кодчилол хайлтын нэг хэсгийг гүйцэтгэх эсвэл хариуг задруулах үед л өргөнийг бууруулсан.

3-р хэсэг — Загвар юуг тооцоолж байна вэ

Probe: холбоост эсэх нь давхарга бүрт аажмаар бүрэлдсэн



- Холбоост эсэх нь давхарга **бүрт** бага багаар уншигдах болж, зөвхөн 4–6-р давхаргад бүрэн уншигдсан
- **Алхмын шатлал байхгүй:** 3 алхмын мэдээлэл 1-р давхаргад гарч ирээд өөрчлөгдөөгүй
- Нарийн загварт холбоост эсэх нь давхарга бүрт илүү удаан бүрэлдэж, сүүлийн давхаргад доогуур түвшинд хүрсэн

16 сургасан загвар, n = 40 / 56, шугаман probe

4-р хэсэг — Жишиг өгөгдлийн шалгалт

Онолын ажлуудын өгөгдөл локал шинжээр шийдэгдсэн

	Sanford тэргүүтэй (GraphQA)	Yehudai тэргүүтэй
тэдний үр дүн	92.9 / 98.0 (1K / 100K граф)	гүн 1–10-д ижил нарийвчлал (100K параметр)
бидний давталт	**93.0 / 98.2**	тэдний кодоор **1.00**, манай загвараар **1.00** (4-р epoch)
локал шийд	2 алхмын ангилагч: **0.995**	зөвхөн ирмэгийн тоо: **0.77**
шаардсан өргөн	$m = 32$ үед 98 хүрсэн	1 давхарга, $m = 64$, 100 сургалтын граф хангалттай

Эдгээр өгөгдөл глобал дүгнэлтгүйгээр шийдэгддэг тул шаардлагатай өргөн графын хэмжээнээс хэрхэн хамаарахыг хэмжихэд тохиромжгүй. Манай `swap` өгөгдөлд бүх локал дүрэм санамсаргүй таамаглалын түвшинд байсан.

Дүгнэлт

Одоогийн дүгнэлт

1. **Өргөнийг хэмжихэд нямбай аргачлал хэрэгтэй.** Сургалтын хурд, өгөгдлийн хэмжээ, өгөгдлийн чанар тус бүр өргөний нөлөөг хуурмагаар үүсгэх эсвэл нууж болно.
2. **Холбоост эсэхийг сурахад шаардлагатай өргөн $n^{1.74}$-ээр өссөн** (n = 32–56). Энэ нь онолоор илэрхийлэхэд хангалттай өргөнөөс хамаагүй их.
3. **Алхмуудыг урьдчилан өгөх нь өргөнийг бууруулсан.** 2 алхмын мөр өргөнийг 2.3–3.2 дахин, өсөлтийг $n^{1.27}$ хүртэл бууруулж, 4 алхмын мөр өсөлтийг бараг шугаман болгосон.
4. **Бүх кодчилол тусалдаггүй.** Ирмэгийн токен илүү өргөн шаардсан, RWSE зөвхөн хариуг задруулсан үед өргөнийг бууруулсан.

Хязгаарлалт ба цаашдын ажил

Хязгаарлалт

- Графын хэмжээ 2 дахин хүрэхгүй мужид (n = 32–56), 2 seed
- Нэг бодлого (холбоост эсэх), нэг архитектур

Цаашдын ажил

- 3-р бүлэг: оролтын кодчилол ба өргөнийг бууруулах боломж
- Хэлэлцүүлэг ба дүгнэлт